


Machine Learning

Projet ML


DE CORDOUE-HECQUARD Grégoire
FERNANDES GUERRA João Paulo

Fréquence de chaque classe





Le dataset est fortement déséquilibré, environ 90% de patients non dépressifs contre 10% de dépressifs, ce qui peut biaiser le modèle vers la classe majoritaire.

Boîte à moustache



Boxplot pour visualiser la distribution et les valeurs aberrantes de toutes les features du dataset. On conclut que les échelles sont trop hétérogènes pour être comparées directement, ce qui justifie la standardisation.

Importance des features par Random Forest




healthcare_equipment domine largement avec une importance autour de 0.030, suivi de BMI, height, pulse et sleep_hours.

Les features Rx_* en haut du graphique ont une importance quasi nulle, ce qui justifie leur exclusion lors de la sélection.

On constate que les features démographiques et biologiques de base sont bien plus discriminantes que les médicaments prescrits.



















Choix du nombre de composantes PCA




30 composantes capturent environ 98% de la variance, ce qui signifie que les 35 features sélectionnées sont relativement indépendantes entre elles, il n'y a pas beaucoup de redondance.

On choisit 30 composantes pour conserver l'essentiel de l'information tout en réduisant légèrement la dimensionnalité.

Histogrammes de
quelques features





Notre dataset est biaisé, donc la majorité des valeurs reflète des patients non dépressifs, donc les valeurs extrêmes et atypiques sont souvent associées à la dépression.

Pairplot

Le dataset est déséquilibré.

x: variables qui représentent l'état de santé général et les comportements :

- BMI et glucose : marqueurs métaboliques classiquement liés à la dépression
- prescriptions_count : indicateur du niveau de maladie globale
- drinks_past_year : comportement à risque

y: variables qui représentent le bien-être et les marqueurs sanguins :

- sleep_hours et sedentary_time : qualité de vie, très liés à la dépression
- hemoglobin et HDL : marqueurs sanguins protecteurs, souvent plus bas chez les dépressifs

